측정 아웃라이어 제거를 통해 개선된 GraphSLAM

GraphSLAM Improved by Removing Measurement Outliers

김륜석*ㆍ최혁두*ㆍ김은태*

Ryunseok Kim, Hyukdoo Choi and Euntai Kim

* 연세대학교 전자전기공학과

요 약

본 논문은 측정값의 우도를 기준으로 선택적인 측정값 적용을 통한 향상된 GraphSLAM을 제안하였다. GraphSLAM은 로 봇의 이동 경로와 환경에 대한 지도를 전체 입력 데이터를 통해 추정한다. 그러나 잡음이 강한 환경에서 센서의 측정치가 부정확한 경우가 늘어나면, 전체 입력 데이터를 사용하는 GraphSLAM의 경우 정확성이 크게 떨어지게 된다. 그러므로 본 논문에서는 들어오는 센서의 측정값들을 선별하여 GraphSLAM에 적용하는 방법을 제안한다. 이 방법을 통해 잡음이 강한 환경에서 기존의 GraphSLAM보다 향상된 성능을 제공할 수 있다.

키워드: GraphSLAM, 측정값 선별, simultaneous localization and mapping(SLAM)

Abstract

This paper presents the GraphSLAM improved by selecting the measurement with respect to their likelihoods. GraphSLAM estimates the robot's path and map by utilizing the entire history of input data. However, GraphSLAM's performance suffers a lot from severely noisy measurements. In this paper, we present GraphSLAM improved by the selective measurement method. Thus the presented GraphSLAM provides higher performance compared with the standard GraphSLAM.

Key Words: GraphSLAM, selective measurement method, simultaneous localization and mapping(SLAM)

1. 서 론

이동 로봇이 선행 정보가 없는 환경을 주행하기 위해서는, 주변 환경에 대한 지도와 자신의 위치에 대한 정보가 필요하다. SLAM(Simultaneous Localization and Mapping)은 이동 로봇이 주행 중 취득한 센서 정보를 이용하여 자신의 위치와 주변 환경에 대한 지도를 추정하는 알고리즘이다[1]. 지난 수십 년 간, SLAM 알고리즘은 이동로봇이 미지의 환경을 주행할 때, 주위 환경에 대한 지도와 자신의 위치를 보다 정확하게 추정하기 위해 다양한 방법으로 발전하여 왔다[2].[3].[4].

GraphSLAM은 SLAM 알고리즘의 여러 방법의 하나로, 로봇의 전체 경로에서 관측되는 랜드마크에 대한 센서 측정 값과 로봇의 이동 정보를 토대로 랜드마크의 지도와 로봇의 전체 경로를 추정하는 Full SLAM의 방법의 하나이다[5].

GraphSLAM은 graph의 노드를 로봇과 랜드마크의 위치로 나타내고 노드 간의 연결을 로봇의 이동정보와 센서의 측정값으로 나타낸다. 확장 칼만 필터 SLAM이 로봇과 랜드마크의 위치에 대한 평균 벡터와 공분산 행렬로 환경을

접수일자 : 2011년 6월 1일 완료일자 : 2011년 8월 1일

본 연구는 지식경제부 산업원천기술개발사업 - 실내로 봇용 인지모델기반 전역 위치인식 기술 개발(과제번호: 10031683)에 의해 수행되었습니다, 연구비 지원에 감사 드립니다. 나타냈던 것과는 다르게, GraphSLAM은 graph의 형태로 로봇과 랜드마크의 위치를 나타낸다[6].

GraphSLAM은 로봇이 이동할 때마다 전체 경로와 랜드 마크들에 대하여 graph를 갱신하고 SLAM에 반영하기 때문에, 로봇의 이동 시간이 길어지고 등록된 랜드마크의 수가 증가함에 따라 graph의 크기가 커지면서 계산량이 매우증가하는 단점이 있다[7]. 또한, GraphSLAM은 입력된 센서의 측정값 전체를 사용하므로, 부정확한 센서의 측정값이 많을 경우, 전체적인 정확성이 떨어지게 된다.

로봇이 잡음이 큰 환경에서 이동하면서 랜드마크에 대한 센서의 측정값을 수집하는 과정에서 측정값에 잡음이 섞이게 된다. 이때, 잡음이 크게 섞인 측정값들을 아웃라이어라 규정하고, 이 아웃라이어는 SLAM을 실행하는 과정에서 지도 구축 오차와 로봇의 위치 추정 오차를 크게 만들어 시스템의 안정성을 떨어뜨리는 요인이 된다[8].

그러므로 본 논문에서는 잡음이 큰 환경에서 이동 로봇이 수집하는 랜드마크에 대한 센서의 측정값 중 아웃라이어들을 선별하여 GraphSLAM에서 제외함으로써, SLAM 시스템이 신뢰도와 안정성을 높이는 방법을 제안한다.

본 논문은 다음과 같이 구성되어 있다. 2장에서는 GraphSLAM과 측정 모델에 대해 설명을 할 것이다. 그리고 3장에서는 센서의 측정치에 대한 우도를 어떻게 계산할지를 2가지 방법으로 접근한다. 경험적으로 정의한 우도와 잡음의 원인을 고려하여 이론적으로 정의된 우도를 소개할 것이다. 4장에서는 3장에서 소개한 두 접근방식과 기존의 GraphSLAM의 알고리즘을 이용하여 주어진 환경에서 시뮬레이션 하여 각각의 알고리즘의 성능을 비교 분석할 것이

다. 5장에서는 4장의 실험 결과에 대하여 고찰하고 앞으로 의 연구방향에 대해 제시할 것이다.

2. GraphSLAM 시스템

2.1 시스템 모델

이번 절에서는 GraphSLAM 시스템의 측정 모델을 다룰 것이다[9]

시간 t에서 로봇의 위치 벡터 x_t 는 다음과 같이 정의된다.

$$x_{t} = (r_{x,t} \ r_{y,t} \ r_{\theta,t})^{T} \tag{1}$$

여기서 r_x, r_y, r_θ 는 각각 로봇의 절대 좌표 x, y와 로봇이 바라보고 있는 각도 θ

로봇이 시간 t-1의 위치에서 시간 t의 위치로 이동할 때의 이동정보의 벡터는 선속도 v_t 와 각속도 ω_t 로 이루어져 있고 다음과 같이 표기한다.

$$u_t = \begin{pmatrix} v_t \\ \omega_t \end{pmatrix} \tag{2}$$

로봇이 이전 위치 x_{t-1} 에서 다음 위치 x_t 로 이동할 때의 이동 모델은 다음과 같이 정의할 수 있다.

$$x_t = g(u_t, x_{t-1}) + N(0, R_t)$$

$$= x_{t-1} + \begin{pmatrix} -\frac{v_t}{\omega_t} sin(r_{\theta,t-1}) + \frac{v_t}{\omega_t} sin(r_{\theta,t-1} + w_t \Delta t) \\ \frac{v_t}{\omega_t} cos(r_{\theta,t-1}) - \frac{v_t}{\omega_t} cos(r_{\theta,t-1} + w_t \Delta t) \\ \frac{v_t}{\omega_t} cos(r_{\theta,t-1}) - \frac{v_t}{\omega_t} cos(r_{\theta,t-1} + w_t \Delta t) \end{pmatrix} + N(0, R_t)$$

$$(3)$$

이동 모델의 잡음은 평균이 0, 분산이 R_t 인 가우시안 분산으로 가정한다. 시간t까지 상태 벡터 $y_{0:t}$ 는 로봇의 초기위치 x_0 에서 현재 위치 x_t 까지의 위치 정보와 N개의 랜드마크의 위치 정보로 이루어져 있다.

$$y_{0:t} = (x_0 \ x_1 \cdots \ x_t \ m_1 \cdots m_N)^T$$
 (4)

랜드마크 j의 위치는 다음과 같이 나타낸다.

$$m_{j} = \begin{bmatrix} m_{j,x} \\ m_{j,y} \end{bmatrix} \tag{6}$$

또한, 로봇이 시간 t에서 i번째로 관측한 랜드마크j에 대한 측정모델은 다음과 같이 정의하도록 한다.

$$\begin{split} z_{t}^{i} &= \begin{pmatrix} \rho_{t}^{i} \\ \rho_{t}^{i} \end{pmatrix} = \begin{pmatrix} \sqrt[3]{(m_{j,x} - r_{x,t})^{2} + (m_{j,y} - r_{y,t})^{2}} \\ atan2((m_{j,y} - r_{y,t}), (m_{j,x} - r_{x,t})) - r_{\theta,t} \end{pmatrix} + N(0, Q_{t}) \\ &= h(m_{j}, x_{t}) + N(0, Q_{t}) \end{split} \tag{7}$$

측정 모델에 대한 잡음은 평균이 0, 분산이 Q_t 인 가우시 안 분산으로 가정한다. 마지막으로 측정모델의 역변환은 다음과 같이 정의한다.

$$\begin{bmatrix}
\widehat{m_{j,x}} \\
\widehat{m_{j,y}}
\end{bmatrix} = h^{-1}(y_t, c_t^i) = \begin{bmatrix} r_{x,t} \\ r_{y,t} \end{bmatrix} + \begin{bmatrix} \rho_j \cos(\phi_j + r_{\theta,t}) \\ \rho_j \sin(\phi_j + r_{\theta,t}) \end{bmatrix}$$
(8)

2.2 GraphSLAM

GraphSLAM의 full posterior는 다음과 같이 나타낼 수 있다.

$$p(y_{0::t}|z_{1::t},u_{1::t},c_{1::t}) = \eta p(y_0) \left[\prod_t [p(x_t|x_{t-1},u_t) \prod_i p(z_t^i|y_t,c_t^i) \right] \quad (9)$$

 $p(x_t|x_{t-1},u_t), p(z_t^i|y_t,c_t^i)$ 는 다음과 같이 나타낼 수 있다.

$$p(x_t|x_{t-1},u_t) = \eta \exp \left\{ -\frac{1}{2} (x_t - g(u_t,x_{t-1}))^T R_t^{-1} (x_t - g(u_t,x_{t-1})) \right\}$$
 (10)

$$p(z_t^i|y_t,c_t^i) = \eta \text{exp} \bigg\{ -\frac{1}{2} (z_t^i - h(y_t,c_t^i))^T Q_t^{-1} (z_t^i - h(y_t,c_t^i)) \bigg\} \ (11)$$

상수 η 와 함께, (9)의 식을 (10),(11)을 이용하여, negative Log 형태로 풀어내면 다음과 같다.

$$\begin{split} &-\log(p(y_{0:t}|z_{1:t},u_{1:t},c_{1:t}) = const\\ &+ \frac{1}{2}[x_0^T \Omega_0 x_0 + \sum_t (x_t - g(x_{t-1},u_t))^T R_t^{-1}(x_t - g(x_{t-1},u_t))\\ &+ \sum_t \sum_t (z_t^i - h(y_t,c_t^i))^T Q_t^{-1}(z_t^i - h(y_t,c_t^i))] \end{split} \tag{12}$$

(12)의 식에서 상수를 제외한 목적 함수 J_{graph} 를 다음과 같이 정리할 수 있다.

$$\begin{split} &J_{graph} = \\ &\frac{1}{2} [x_0^T \Omega_0 x_0 + \sum_t (x_t - g(x_{t-1}, u_t))^T R_t^{-1} (x_t - g(x_{t-1}, u_t)) \\ &+ \sum_t \sum_i (z_t^i - h(y_t, c_t^i))^T Q_t^{-1} (z_t^i - h(y_t, c_t^i))] \end{split} \tag{13}$$

GraphSLAM은 (13)의 식을 최소화 하는 y를 SLAM에 반영한다. 그림 1은 (13)을 그림으로 묘사한 것이다. 그림 1과 같이 로봇의 모든 경로와 랜드마크를 Graph의 노드로 정의한다. Graph에서 로봇의 위치 노드 간의 연결은 로봇의 이동 정보이고 랜드마크 노드와 로봇위치 노드 간의 연결은 센서의 측정값으로 한다.

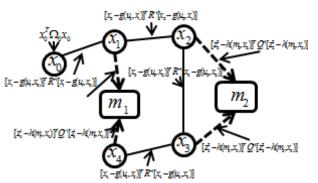


그림 1. GraphSLAM 묘사도 Fig 1. GraphSLAM illustration

그림 2와 같이 GraphSLAM에서 같은 랜드마크에 대해 여러 측정값이 존재할 것이고, 이 측정값들은 환경의 잡음 이 섞인 상태로 측정될 것이다. 랜드마크를 새로 측정할 때 마다 graph에 엣지가 갱신되는데, 이때 들어오는 측정값이 잡음이 섞여 부정확하다고 판단된다면 업데이트를 하지 않 고 비교적 정확하다고 판단되는 다른 측정값을 사용할 수 있을 것이다

같은 랜드마크에 대한 측정값들을 서로 비교하여, 측정값의 정확도에 따라 가중치를 부여한다면 새로 측정한 측정값이 부정확한 측정값인지 정확성이 높은 측정값인지를 판단할 수 있을 것이다.

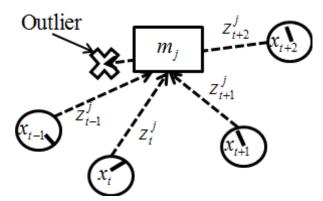


그림 2. 랜드마크에 대한 센서 측정값의 분포 Fig 2. Distribution of measurements from various robot poses

3. 측정값의 아웃라이어 제거를 통한 GraphSLAM

3.1 경험적으로 예측하여 정의한 센서 측정값의 우도

잡음이 많은 환경에서 로봇이 시간 t에서 i번째 랜드마크를 센서로 관측할 때, 측정값들의 불확실성을 판단하기위해서 측정값에 대한 우도를 실험적으로 다음과 같이 정의하였다.

$$\begin{split} w_t^i &= \det(2\pi S_j)^{-1} \\ &\times \exp\!\left\{\! -\frac{1}{2}(h^{-1}(x_t, z_t^i) - \overline{m_j})^T S_j^{-1}(h^{-1}(x_t, z_t^i) - \overline{m_j})\right\} \end{split} \tag{14}$$

 S_j 는 각 시간 k에서 관측된 랜드마크 j의 절대 좌표의 불확실성에 대한 공분산을 가리킨다.

$$S_{j} = \frac{\sum_{k=0}^{t} a_{k}^{j} (h^{-1}(x_{k}, z_{k}^{e_{k}^{i}}) - \overline{m_{j}})^{T} Q_{k}^{-1} (h^{-1}(x_{k}, z_{k}^{e_{k}^{i}}) - \overline{m_{j}})}{\sum_{k=1}^{t} a_{k}^{j}}$$
(15)

여기서, $e_k^i=j$ 는 시간 k에서 랜드마크 j에 대한 측정번 호이고, a_k^j 는 시간k에서 랜드마크 j에 대한 측정번호가 들어왔으면 1, 아니면 0이다. m_j 는 랜드마크 j에 대한 센서의 측정 모델의 역변환으로 구한 절대좌표들의 평균이다.

$$\overline{m_j} = \frac{\sum_{k=1}^t a_k^j h^{-1}(x_t, z_k^{e_k^i})}{\sum_{k=1}^t a_k^j}$$
(16)

(14)의 식에서 구한 우도를 사용하여, 시간 t에서 랜드마크 j에 대한 센서의 측정값이 아웃라이어 여부를 판단하기위해서, 측정값에 대한 가중치를 정의한다. 우도 값이 경계값 τ 보다 클 경우 가중치를 1로, 그렇지 않은 경우 0으로 설정한다.

$$L_t^i = \begin{cases} 1 & w_t^i \ge \tau \\ 0 & otherwise \end{cases}$$
 (17)

(12)의 식에서 센서의 측정값을 선별 적용하기 위해 측정 값의 가중치를 적용하여 다시 쓰면 다음과 같다.

$$J_{graph} = \frac{1}{2} [x_0^T \Omega_0 x_0 + \sum_t (x_t - g(x_{t-1}, u_t))^T R_t^{-1} (x_t - g(x_{t-1}, u_t)) + \sum_t \sum_i L_t^i (z_t^i - h(y_t, c_t^i))^T Q_t^{-1} (z_t^i - h(y_t, c_t^i))]$$

$$(18)$$

(18)의 식을 통하여, 센서의 측정값을 선별하여 GraphSLAM에 적용할 수 있다.

3.2 이론적으로 정의한 센서 측정값의 우도

이번 장에서는, 이론적 근거를 기반으로 센서 측정값의 우도를 정의하려 한다. 3.1절에서 정의 한 (14)의 식은 랜드 마크에 대한 센서 측정값들의 평균과 분산을 계산하여, 그 에 따라 우도를 유도하였다. 그러나 이 방법의 경우, 단순히 측정값들의 평균과 분산을 이용하였고 센서의 측정값에 대한 불확실성의 원인에 대해서 이론적 근거를 마련하지 못하였다.

따라서 센서의 측정값에 대한 불확실성의 원인을 생각해보면, 센서 자체의 측정 잡음과 현재 알고 있는 랜드마크와로봇의 위치에 대한 불확실성을 생각해볼 수 있다. 그렇다면 시간 t에서 i번째 랜드마크에 대한 불확실성의 공분산 S_i^t 은 다음과 같이 정의할 수 있다.

$$S_t^i = Q_t + H_t^i \Sigma (H_t^i)^T \tag{18}$$

 Σ_t^i 는 GraphSLAM의 공분산이고, H_t^i 는 시간 t에서 i번째 랜드마크를 측정했을 때 측정 모델의 자코비안 (Jacobian)이며 다음과 같이 정의할 수 있다.

$$H_{t}^{i} = \left[\frac{\partial h}{\partial y_{0 \cdot t}^{i}}\right] = \left[O_{2 \times t} \frac{\partial h}{\partial x_{t}} O_{2 \times j-1} \frac{\partial h}{\partial m_{j}} O_{2 \times N-j}\right]$$
(19)

여기서

$$\begin{split} \frac{\partial h}{\partial x_t} &= \begin{bmatrix} -\left(m_{j,x} - r_{x,t}\right) & -\left(m_{j,y} - r_{y,t}\right) & 0 \\ -\left(m_{j,y} - r_{y,t}\right) & -\left(m_{j,x} - r_{x,t}\right) \\ \rho_j^2 & -\frac{\left(m_{j,x} - r_{x,t}\right)}{\rho_j^2} & 1 \end{bmatrix}, \\ \frac{\partial h}{\partial m_j} &= \begin{bmatrix} \left(m_{j,x} - r_{x,t}\right) & \left(m_{j,y} - r_{y,t}\right) \\ \left(m_{j,y} - r_{y,t}\right) & \left(m_{j,x} - r_{x,t}\right) \\ \rho_j^2 & \frac{\rho_j^2}{\rho_j^2} & \frac{\rho_j^2}{\rho_j^2} \end{bmatrix} \end{split}$$

(18)과 (19)의 식을 바탕으로 센서의 측정값에 대한 우도 를 다시 쓰면 다음과 같다.

$$w_t^i = \det(2\pi S_t^i)^{-1} \times \exp\left\{-\frac{1}{2}(z_t^i - \overline{z_t^i})^T [S_t^i]^{-1} (z_t^i - h(y_t, c_t^i))\right\}$$
(20)

$$\begin{split} J_{graph} &= \frac{1}{2} [x_0^T \Omega_0 x_0 + \sum_t (x_t - g(x_{t-1}, u_t))^T R_t^{-1} (x_t - g(x_{t-1}, u_t)) \\ &+ \sum_t \sum_i L_t^i (z_t^i - h(y_t, c_t^i))^T Q_t^{-1} (z_t^i - h(y_t, c_t^i))] \end{split} \tag{21}$$

여기서,
$$L_t^i = \begin{cases} 1 & w_t^i \geq \tau \\ 0 & otherwise \end{cases}$$

이론적으로 정의한 우도를 목적 함수 J_{Graph} 에 적용하여, 센서의 측정값을 선별할 수 있다. 아웃라이어들을 제거하고 비교적 정확한 센서의 측정값들을 GraphSLAM에 적용한다면, 로봇의 전체 경로 오차와 지도의 작성 오차를 줄일

수 있을 것으로 예상하며, 측정치의 아웃라이어에 의해 SLAM의 성능이 크게 떨어지는 경우를 예방할 수 있을 것이다. 또한, 실험적으로 정의한 우도와 비교하면, 3.1절에서는 한 랜드마크에 대한 전체 센서 측정치의 평균을 통해 우도를 계산하려 하였으므로 측정치의 아웃라이어에 대한 영향을 많이 받게된다. 그러나 이번 절에서 제안한 방법의 경우, 아웃라이어의 영향을 최소화하므로 GraphSLAM에 적용하면 더욱 나은 성능을 보여줄 것이다.

4. 시뮬레이션 결과

이 장에서는 본 논문에서 제안한 방법을 적용한 GraphSLAM과 기존의 GraphSLAM의 성능 차이를 알아보기 위한 시뮬레이션을 하였다.

본 논문에서는, 센서의 측정치에 대한 잡음이 강한 환경일수록 발생 빈도가 늘어나는 측정치의 아웃라이어에 대해 선별작업을 통해 GraphSLAM의 성능을 향상하기 위한 알고리즘을 제안하였으므로, 먼저 센서의 측정치에 대한 잡음이 적은 환경에서 시뮬레이션하고, 다시 잡음을 5배 강화한 환경에서 시뮬레이션하는 것으로 성능 비교를 하기로 한다. 시뮬레이션 횟수는 20번으로 설정하였고 지도의 작성 오차와 로봇의 경로 추정 오차의 평균으로 각 방법의 성능차이를 비교하였다. 시뮬레이션은 MATLAB에서 이루어졌으며,로봇의 전체 경로와 랜드마크는 같게 설정하였다.

다음 그림3은 일반적인 환경에서의 시뮬레이션 결과이다. 그림 3에서 실선은 로봇의 실제 경로이고, 점선은 추정되는 로보봇의 경로이다. 그리고 작은 원은 실제 랜드마크의 위 치이고, 파란 마름모는 추정되는 랜드마크의 위치이다.

그림을 보면, 로봇의 실제 경로와 SLAM으로 추정한 경로의 오차가 크지 않고, 지도 작성 오차 역시 크게 차이가 없음을 볼 수 있다.

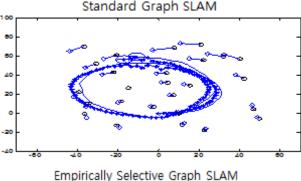
다음의 표 1은 잡음이 적은 환경에서 GraphSLAM으로 20번의 시뮬레이션을 한 결과의 평균이다. 잡음이 적은 일 반적인 환경에서는, 3.2절에서 제안한 방법이 가장 나은 성능을 보여주었고, 3.1절에서 제안한 방법과 기존의 방법은 큰 차이를 보여주지 않았다.

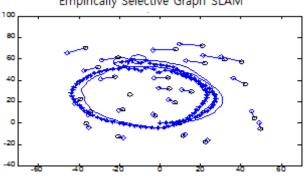
표 1. 잡음이 적은 환경에서 기존의 방법과 제안된 방법들의 위치 및 지도 추정 오차

Table 1. Localization and mapping errors of the standard method and the proposed methods in the environment with small noise

	기존 방법	실험적 선별 방법	이론적 선별 방법
위치 추정 오차(cm)	42.3368	45.9797	38.1276
지도 추정 오차(cm)	60.9451	56.1417	36.1822

그림4는 센서의 측정치에 대한 잡음을 5배로 강화한 환경에서 GraphSLAM을 시뮬레이션한 결과이다. 기존의 방법의 성능이 크게 악화한 반면에, 3.1절에서 제안한 방법과 3.2절에서 제안한 방법은 기존의 방법과 비교하여 성능이크게 악화하지 않았다. 특히 3.2절에서 제안한 방법의 성능의 악화 폭이 적음을 알 수 있다.





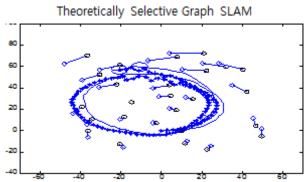


그림 3. 잡음이 적은 환경에서 세 가지 GraphSLAM의 시뮬레이션 비교

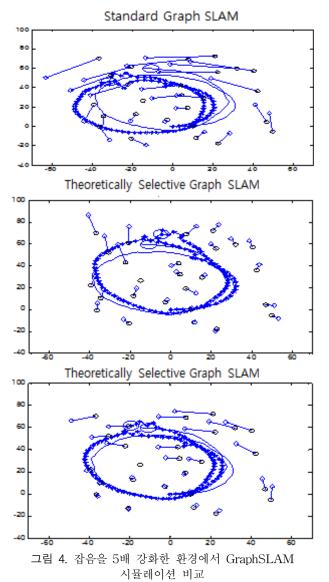
- (a) 기존의 GraphSLAM (b) 3.1절에서 제안한 실험적으로 측정치를 선별하는 GraphSLAM
 - (c) 3.2절에서 제안한 이론적으로 측정치를 선택하는 GraphSLAM

Fig. 3. Comparison of the three GraphSLAM methods in the environment with small noise

(a)Standard GraphSLAM (b) Empirically selective GraphSLAM, (c) Theoretically selective GraphSLAM

다음의 표 2는 잡음이 큰 환경에서 GraphSLAM에 각각의 방법을 적용하여 시뮬레이션한 결과의 평균이고, 표를보면, 3.1절에서 제안한 방법을 적용한 GraphSLAM은 지도 작성에서 13%, 경로 추정에서 12%의 성능 향상을 보이고 있으며, 3.2절에서 제안한 방법을 적용한 GraphSLAM에서는 각각 43%, 47%의 성능 향상을 보이고 있다.

기존의 GraphSLAM은 센서의 측정값이 아웃라이어일 경우에도 SLAM에 적용함에 따라, 점차 오차가 증가하게 된다. 반면에, 본 논문 3.1절에서 제안한 방법은 대상에 대한 잡음이 큰 정보가 들어올 경우, 부정확하다고 판단하여



(a)기존의 GraphSLAM (b) 3.1절에서 제안한 실험적으로 측정치를 선택하는 GraphSLAM

(c) 3.2절에서 제안한 이론적으로 측정치를 선택하는 GraphSLAM

Fig. 4. Comparison of the three GraphSLAM methods in the environment with 5 times reinforced noise.(a)Standard GraphSLAM (b)Empirically selective GraphSLAM, (c) Theoretically selective GraphSLAM

정보를 버리기 때문에 잡음이 큰 환경에서 GraphSLAM의 성능이 크게 악화하지 않았다. 그러나 이 방법은 측정값들의 평균과 비교하기 때문에, 측정값의 정확도를 판단하는 근거가 약했고, 특정 환경에서는 기존의 GraphSLAM보다성능이 떨어지는 문제점이 있다. 3.2절에서 제안한 방법은 3.1절에서 제안한 방법보다 불확실성을 예측하는 이론적 근거를 강화하였다. 그 결과, 표 2에서 알 수 있듯이, 기존의 GraphSLAM과 3.1절에서 제안한 방법보다 성능이 향상되었음을 확인할 수 있었다.

표 2. 잡음을 5배 강화한 환경에서 기존의 방법과 제안된 방법들의 위치 및 지도 추정 오차

Table 2. Localization and mapping errors of the standard method and the proposed methods in the environment with 5 times reinforced noise

	기존 방법	실험적 선별 방법	이론적 선별 방법
위치 추정 오차(cm)	324.15	284.235	186.289
지도 추정 오차(cm)	376.36	327.63	201.773

5. 결론 및 고찰

본 논문에서 우리는 잡음이 강한 환경에서 센서의 측정 값을 정확도에 따라 GraphSLAM에 선별 적용함으로써, SLAM의 성능을 향상하는 방법을 제안하였다. 또한, GraphSLAM에 센서의 측정값을 선별 적용하는 방법에 대 해 실험적인 방법과 이론적인 방법을 각각 적용하여 성능을 비교하였다. 결과적으로 3.2절에서 제안한 방법을 통하여 센서의 측정값의 아웃라이어를 효과적으로 선별할 수 있었 고, GraphSLAM의 성능을 상당히 향상할 수 있었다. 그러 센서의 측정값을 본 논문에서는 GraphSLAM의 아웃라이어를 효과적으로 제거함으로써 성 능을 향상할 수 있음을 보였다. 앞으로는, 센서의 측정값에 대한 우도를 정해진 경계 값에 따라 선별하지 않고, 시스템 에서 센서의 측정값의 우도의 수치에 따라 경계 값을 적응 적으로 결정할 수 있는 알고리즘을 연구할 것이다.

참 고 문 헌

- [1] Ila,V.,J.M. Porta, et al. (2010). "Information-Based Compact Pose SLAM." *IEEE Transactions on Robotics*, vol. 26, no.1, pp. 78–93.
- [2] Cheein, F. A., G. Scaglia, et al. (2009). "Feature Selection Criteria for Real Time EKF-SLAM Algorithm." *International Journal of Advanced Robotic Systems*, vol. 6, no. 3, pp. 229–238.
- [3] Grisetti, G., Ku, et al. (2010). "A Tutorial on Graph-Based SLAM." *Intelligent Transportation Systems Magazine, IEEE*, vol. 2, no. 4, pp. 31–43.
- [4] Kim, C., R. Sakthivel, et al. (2008). "Unscented FastSLAM: A Robust and Efficient Solution to the SLAM Problem." *Robotics, IEEE Transactions*, vol. 24, no. 4, pp. 808–820.
- [5] Guivant, J. E., F. R. Masson, et al. (2002). "Simultaneous localization and map building using natural features and absolute information." *Robotics and Autonomous Systems*, vol. 40, no. 2–3, pp. 79–90.
- [6] Kummerle, R., B. Steder, et al. (2011). "Large scale graph-based SLAM using aerial images as prior information." *Autonomous Robots*, vol. 30, no. 1, pp. 25–39.

- [7] 오정석, 심귀보(2010). "대칭모형기반SLAM : M-SLAM." 한국지능시스템학회 논문지, 제20권, 4호, pp. 463-468.
- [8] Steder, B., G. Grisetti, et al. (2008). "Visual SLAM for Flying Vehicles." *Ieee Transactions on Robotics*, vol. 24, no. 5, pp. 1088–1093.
- [9] 김동엽, 최혁두, 황재필, 김은태, 김영욱, 슬램 수행을 위한 천장의 원형 특이점에 관한 연구, 한국 지능시스템 학회 2009년도 추계학술대회 학술발표 논문집, 제 19권,2호,pp. 74-76, 제주, 2009년 12월

저 자 소 개



김륜석(Ryunseok Kim)

2010년 : 연세대학교 전기전자공학부 졸업. 2010년 ~ 현재 : 동 대학원 전기전자공학과 석사과정

관심분야 : SLAM

E-mail : Alcheringa@yonsei.ac.kr



최혁두(Hyukdoo Choi)

2009년 : 연세대학교 전기전자공학부 졸업. 2009년 ~ 현재 : 동 대학원 전기전자공학과 석사과정

관심분야 : SLAM, Mobile Robot E-mail : goodgodgd@yonsei.ac.kr



김은태(Euntai Kim)

1992년 : 연세대학교 전자공학과 졸업 (공학사)

1994년: 연세대학교 전자공학과 석사과정 졸업(공학석사)

1999년: 연세대학교 전자공학과 박사과정 졸업(공학박사)

199년 3월~2002년 2월:국립한경대학교 제어계측공학과 조교수

2002년 3월~현재: 연세대학교 전기전자공학부 교수 2003년: University of Alberta, visiting researcher 1998년~현재: IEEE TFS, IEEE T SMC, IEEE TCAS,

FSS등에서 심의위원 활동 중 2003년: 대한 전자공학회 해동상 수상

관심분야: Computational Intelligence, 지능형 로봇

Phone : 010-5177-2863 E-mail : etkim@yonsei.ac.kr